

Научная конференция «Гагаринские чтения»


Разработка рекомендательной системы

МАШИННОЕ ОБУЧЕНИЕ

ОБРАБОТКА ЕСТЕСТВЕННОГО ЯЗЫКА

ОТКРЫТЫЕ ДАТАСЕТЫ

Выполнил Чёрный Д.А. группа М8О-404Б-22



Постановка задачи

Цель исследования

Разработка рекомендательной системы на основе текстов отзывов пользователей маркетплейса — без опоры на явные числовые рейтинги.

Промежуточные задачи


- Классификация отзыва по тексту → определение категории товара
- Семантический поиск товаров по произвольному текстовому запросу
- Сравнение нескольких методов классификации и поиска

Почему отзывы?

Аргументированная оценка — отзыв содержит контекст, недоступный в числовом рейтинге

Профиль пользователя — строится без явной анкеты на основе истории отзывов

Холодный старт — решается для новых товаров через семантическое сходство текстов



Данные и инструментарий

Источник данных

Открытые датасеты с маркетплейса Wildberries. Хранение — PostgreSQL в Docker (порт 5433).

Таблица	Ключевые поля
<i>wb_products</i>	<i>nm_id, imt_name, subj_root_name, description</i>
<i>wb_reviews</i>	<i>nm_id, review_text, product_valuation</i>

Загрузка отзывов продолжалась значительное время. Чтобы при аварийном завершении программы не приходилось начинать чтение датасетов сначала, система каждые несколько сотен тысяч отзывов создавала контрольные точки. В случае аварийного завершения программы чтение начиналось с последней сохраненной точки.

Технологический стек



PostgreSQL + Docker

Хранение и выборка данных



Python

pandas, SQLAlchemy — работа с данными



Трансформеры

sentence-transformers, PyTorch — векторизация и обучение




scikit-learn + h5py

Классификаторы, метрики и HDF5-кеширование

Предобработка и векторизация

Конвейер обработки текста



Три модели — три пространства эмбедингов

Модель	Dim	Особенность
rubert-base-cased-sentence	768	Специализирована на русском
MiniLM-L12-v2	384	Лёгкая, без префиксов
multilingual-e5-large	1024	Префиксы query: / passage:

Формирование текста товара

```
input = imt_name + ". " + description
```

Валидация

Разбивка: train 70% / val 15% / test 15% со стратификацией по классу товара.

Выбор модели векторизации: от Word2Vec к трансформерам

Этапы экспериментов с моделями

Модель	Подход	Результат
Word2Vec (nlp_65)	Усреднение векторов слов	Низкая точность
text2vec-base-multilingual	Sentence embedding	Недостаточная точность
MiniLM-L12-v2	Sentence Transformer	✓ Хорошая точность
rubert-base-cased-sentence	Sentence Transformer (RU)	✓ Хорошая точность
multilingual-e5-large	Sentence Transformer + префиксы	✓ Хорошая точность

Критерий выбора финальных моделей

Высокая F1-мера при классификации отзывов → пространство

эмбеддингов хорошо разделяет категории → тот же индекс

возможно применить для поиска товаров.

Почему word2vec не справился

- **OOV-слова:** «вайлдберриз», «лонгслив», «артикулы» отсутствуют в словаре
- **Статические векторы:** «не нравится» ≠ «нравится» неразличимы
- **Усреднение** устраняет различия в семантике длинных отзывов

Финальное количество записей: 473839

Уникальных корневых категорий: 51

=== Результаты на тесте ===

Точность предсказания корневой категории: 0.7275

Почему text2vec не справился

- **Модель** не обучена понимать контекст
- **Трудности при поиске сходства** возникают уже на этапе сравнения эмбеддингов предложений

```
query = "Как сменить пароль?"
candidates = [
    "Забыл пароль, что делать?",
    "Как восстановить доступ?",
    "Сегодня солнечно.",
    "Где ближайший супермаркет?"
```

Запрос: 'Как сменить пароль?'

Наиболее похожий кандидат: 'Где ближайший супермаркет?' (сходство: 0.9495)

Три метода: классификация и поиск

	Метод А — Логистическая регрессия	Метод Б — Центроиды	Метод В — Сиамская сеть
Классификация: что происходит	Вектор отзыва умножается на матрицу весов. Каждый класс получает числовой балл. Предсказывается класс с максимальным баллом	Вычисляется cosine-сходство вектора отзыва с каждым центроидом. Предсказывается класс ближайшего центроида	Вектор отзыва и вектор названия каждой категории подаются в общий энкодер. Голова сети выдаёт балл принадлежности для каждой пары
Откуда берётся «образ» категории	Подбирается обучением: веса настраиваются так, чтобы отзывы своей категории получали высокий балл	Считается вручную: среднее эмбедингов всех обучающих отзывов этой категории	Текстовое название категории («Обувь», «Электроника») кодируется той же сетью
Поиск: как кодируется запрос	Запрос → языковая модель → вектор 768	Запрос → языковая модель → вектор 768	Запрос → языковая модель → энкодер сети → вектор 512
Поиск: как выбирается категория	Пользователь задаёт ручную	Автоматически: запрос сравнивается с центроидами, выбирается ближайший	Пользователь задаёт ручную
Поиск: с чем сравнивается запрос	С эмбедингами товаров в пространстве языковой модели (768)	С эмбедингами товаров в пространстве языковой модели (768)	С эмбедингами товаров, прогнанными через тот же энкодер (512)
Почему индексы несовместимы	Методы А и Б используют один индекс — пространство одинаковое		Метод В строит новое метрическое пространство — нельзя смешивать с А и Б

Результаты: классификация

Метрика: F1-мера взвешенная

Weighted F1 выбрана из-за несбалансированности классов между категориями товаров.

$$F1 = 2 \frac{Precision \cdot Recall}{Precision + Recall}$$

Результаты на тестовой выборке модели RuBERT

Метод	F1 val	F1 test
А: Логистическая регрессия	0.8321	0.8317
Б: Центроиды	0.5692	0.5671
В: Сиамская сеть	0.8176	0.8161


Матрица ошибок

Матрица ошибок показывает, между какими категориями возникают наибольшие ошибки классификации — где категории семантически близки.




Истинное

[Б] Центроидный классификатор — Confusion Matrix (test)



[В] Сиамская сеть — Confusion Matrix (test)



Результаты: поиск товаров

Выводы и перспективы

Что сделано

01

Реализованы и сравнены **3 метода классификации** отзывов (А, Б, В)

02

Реализован **семантический поиск** товаров по текстовому запросу

03

Протестированы **3 языковые модели**: RuBERT, MiniLM, E5-large

04

Построена система **кеширования эмбедингов** (HDF5) и проведена комплексная оценка

Ключевые наблюдения

- Методы А и Б работают в одном пространстве — разница в механизме классификации
- Метод В строит новое метрическое пространство, где запросы и товары сопоставимы
- Метод Б — единственный с **автоматическим определением категории** при поиске

Перспективы развития



REST API и веб-интерфейс

Интеграция с внешними сервисами и демонстрационный интерфейс для работы с системой



Гибридный поиск

Для переранжирования найденных товаров и поиска точных совпадений
top-50 → top-10



Улучшение модели

Дообучение модели на словах, не встречающихся в словаре модели – англицизмы, опечатки. Расширение вычислительных ресурсов и большее разнообразие товаров.

Практические проблемы и их решения

1

Дисбаланс классов

Без балансировки модель переобучается на больших категориях товаров.

1. *Догрузка малых классов (< 200 отзывов) из базы данных*
2. *Удаление классов с < 100 отзывов*
3. *Обрезка больших классов до 2000 отзывов*

2

Вычислительные ресурсы

*Векторизация сотен тысяч отзывов
отзывов × 3 модели — многочасовая операция.*

Решение — кеширование в HDF5:

- `reviews_embeddings_rubert.h5` ←
Файл 1
- `products_raw_rubert.h5` ← Файл 2
- `products_siamese_rubert.h5` ←
Файл 3

3

Чтение данных из БД

*Загрузка большого объёма данных
единым запросом приводит к
исчерпанию памяти.*

Решение — чанковое чтение:

```
pd.read_sql(query, engine,  
chunksize=10_000)
```

*Данные обрабатываются порциями по
10 000 строк, что позволяет работать с
миллионами записей при ограниченной
RAM.*